

Mineração de Microdados do ENEM para Identificação de Escolas com Bom Desempenho em TIC em Contextos Socioeconômicos Desfavoráveis

Felipe Lacerda Tertuliano¹, Maria Inês Martins¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
30.535-901 - Belo Horizonte - MG - Brazil

Abstract. *This work proposes the development of an analytical mechanism to identify schools in the public basic education network as targets for training interventions in Information and Communication Technologies (ICT). Using microdata from ENEM and the School Census, the methodology involves large-scale data analysis, crossing student performance in the national exam with socioeconomic indicators and school characteristics. The objective is to identify institutions with performance that deviates from expectations to direct public policies and resources more effectively, resulting in a prototype, such as reproducible scripts or a panel of indicators, contributing to applied data science, education and training in ICT in Brazil.*

Resumo. *Este trabalho propõe o desenvolvimento de um mecanismo analítico para identificar escolas da rede pública de ensino básico como alvo para intervenções em capacitação em Tecnologias da Informação e Comunicação (TIC). Utilizando microdados do ENEM e do Censo Escolar, a metodologia envolve a análise de dados em larga escala, cruzando o desempenho dos estudantes no exame nacional com indicadores socioeconômicos e características das escolas. O objetivo é identificar instituições com desempenho que fogem ao esperado para direcionar políticas públicas e recursos de forma mais eficaz, resultando em um protótipo, como scripts reprodutíveis ou um painel de indicadores, contribuindo para a ciência de dados aplicada, à educação e a formação em TIC no Brasil.*

1. Introdução

A educação é o principal pilar para o desenvolvimento de qualquer área técnica, especialmente no processo de capacitação em que as condições materiais e sociais como a renda, ambiente de estudo, etnia ou gênero podem afetar as oportunidades e o desenvolvimento desses futuros profissionais. No Brasil a desigualdade social, violência, baixos investimentos e vários outros fatores (característicos de países de terceiro mundo) afetam diretamente o processo de escolarização ainda podemos verificar casos de sucesso, entretanto no meio de tantos exemplos é difícil identificar quais e como essas exceções geraram esses resultados. Esse trabalho tem como objetivo o desenvolvimento de um mecanismo analítico para identificar escolas-alvo para intervenções de capacitação em Tecnologias da Informação e Comunicação (TIC) para alunos da rede pública de ensino básico. O mecanismo de identificação se pautará em dados públicos, sobretudo no cruzamento de de informações extraídas dos microdados do Exame Nacional do Ensino Médio (ENEM)

e dos microdados do Censo Escolar, ambos disponibilizados anualmente pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Partindo do pressuposto de que o desempenho educacional em competências digitais depende, para além da infraestrutura tecnológica disponível, de fatores pedagógicos e institucionais, podemos identifica-los por meio da análise de dados educacionais em larga escala. Nesse contexto, a construção de um sistema de análise orientado por dados pode contribuir para orientar políticas públicas de formação e apoio às escolas, especialmente em contextos socioeconômicos mais vulneráveis. Os microdados contêm informações detalhadas sobre o desempenho dos participantes nas diferentes áreas do exame, variáveis relacionadas ao perfil socioeconômico dos estudantes e dados das escolas.

A proposta consiste em extrair, tratar e organizar esses dados utilizando técnicas de tratamento de grandes bases de dados, análise estatística e de agrupamento, possibilitando a construção de indicadores comparáveis entre escolas. A análise privilegiará o cruzamento entre três conjuntos de variáveis: 1. o desempenho dos estudantes em competências associadas ao uso e à compreensão de Tecnologias da Informação e Comunicação, 2. os indicadores socioeconômicos declarados pelos participantes no questionário contextual do ENEM e 3. As características específicas da instituição de ensino em que esse participante se formou. Para o desempenho, serão consideradas competências presentes na Matriz de Referência (MR) do ENEM da área de Linguagens, Códigos e suas Tecnologias (C1 e C9) e na MR de Matemática e suas Tecnologias (C7), por estarem relacionadas a habilidades de interpretação de informações, resolução de problemas e uso de recursos tecnológicos e informacionais. Os indicadores socioeconômicos permitirão, de outro lado, caracterizar o perfil dos estudantes e/ou da escola e construir índices sintéticos ou classificações que representem as instituições. O cruzamento entre desempenho nas competências selecionadas e a situação das escolas permitirá identificar padrões de desempenho que escapam às expectativas associadas às condições SE e, se possível, infraestruturais.

A identificação dessas unidades escolares, com desempenho resiliente, permitirá orientar ações de capacitação em TIC baseadas em evidências, direcionando recursos e estratégias para contextos em que tais intervenções possam produzir maior impacto. Como produto final, pretende-se desenvolver um protótipo de mecanismo de identificação de escolas-alvo, que poderá assumir a forma de um conjunto de rotinas de análise de dados, scripts reproduzíveis ou mesmo um painel analítico que permita visualizar e comparar indicadores educacionais e socioeconômicos. Espera-se que a proposta contribua tanto para o campo da ciência de dados aplicada à educação quanto para o aprimoramento de estratégias de formação em TIC no sistema educacional brasileiro.

2. Revisão de Literatura

O Exame Nacional do Ensino Médio (ENEM) foi criado em 1998 no Brasil com o intuito de avaliar a educação na rede de escolas do ensino médio nacionais e depois (em 2009), junto do Sistema de Seleção Unificada (Sisu) e ao Programa Universidade para Todos (ProUni), adaptado como mecanismo de acesso à educação superior. Ainda hoje o ENEM é uma das principais formas de democratização do ensino e métrica para se avaliar tendências na educação no país, permitindo base concreta para o desenvolvimento de políticas públicas.

Dentre outras ferramentas no país o Censo Escolar, coordenado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), permite se aprofundar ainda mais na análise sobre ensino Brasileiro. Sendo feito anualmente e com caráter declarativo obrigatório para as escolas da educação básica o censo provê dados da estrutura dessas instituições que também servem de métrica para ações no país.

Entretanto, somente a disponibilidade desses dados [Inep 2025b] [Inep 2025a] não permite um entendimento concreto sobre a educação, nem muito traçar uma abordagem compatível com a realidade do Brasil. Em "Influência Da Renda No Desempenho Dos Estudantes No Enem: Uma Análise Longitudinal"[Filho et al. 2025], que fez uma análise de todas as edições do ENEM até 2023 cruzando os dados do questionário socioeconômico com as notas do exame, foi avaliado que durante todos os anos a renda familiar foi um fator decisivo para a nota dos alunos. Nele também é constatado da importância da ação direcionada para as escolas públicas e em situação desfavorável, pois são nessas escolas em que se encontram os estudantes mais afetados pela desigualdade social.

Especificamente quando se discute áreas do conhecimento disparidades mais complexas podem aparecer, como em "The Analysis of Mathematics Performance in the National High School Exam in Brazil"[Marcom and Papani 2024], onde se analisou a desempenho dos candidatos nos teste de matemática do ENEM 2022 com recortes geográficos e de gênero. Nele se mostrou que mulheres, em todos os casos, tinham piores resultados nessa área do exame, o que pode significar uma deficiência no nosso sistema no que se diz sobre de ensino de exatas.

Assim a proposta do desenvolvimento de uma ferramenta capaz de mapear esses fatores e identificar pontos de atenção se mostra uma solução possível mas também necessária. Na dissertação "Análise dos microdados do Enade: proposta de uma ferramenta de exploração utilizando mineração de dados"[Araújo 2019] utilizando metodologias de mineração e *machine learning* foi construída uma ferramenta *web* de análise. Entre os achados à partir dos dados foi possível gerar regras que representam condições de alunos dentro do ensino superior, o que é uma forte ferramenta para intervenções direcionadas.

3. Metodologia

Para o objetivo do projeto foram escolhidas duas base de dados a serem tratadas: microdados do ENEM 2024 [Inep 2025b] e microdados do censo escolar 2024 [Inep 2025a]. A partir dessas bases foi iniciada a produção de uma ferramenta na linguagem de programação *Rust* [Rust Team 2026] que seja capaz de ler os microdados, tratá-los e processá-los, gerando em fim indicadores relevantes para a proposta. Um repositório [Tertuliano 2026] no *GitHub* [GitHub Team 2026] foi criado para o versionamento e escolhida a *IDE VSCode* [VSCode Team 2026] para o desenvolvimento.

3.1. Extração dos dados

Para extrair os dados de ambas as bases [Inep 2025b] [Inep 2025a] foi criado uma característica chamada *Data Source* capaz de acessar a fonte na *internet*, baixar, descompactar e salvar essas localmente. Junto disso a *Data Source* seria capaz de percorrer o arquivo e obter os elementos a serem processados pelo programa.

...

```
pub trait DataSource<'a>: Sized {
    fn get_web_source(&self) -> String;

    fn get_source_path(&self) -> String;

    fn get_struct_path(&self) -> String;

    fn new() -> Self;

    fn get_ref(&self) -> GlobalRes<PathBuf> ...

    fn get_header(&self) -> GlobalRes<Vec<String>> ...

    async fn init() -> GlobalRes<Self> ...
}
...
```

Para a extração das múltiplas bases, devido a dependência de comunicação com a *internet* que gera grandes períodos de espera, essas foram colocadas para serem executadas de forma assíncrona. Dessa forma por enquanto ocorre hiatos em um processo o outro pode executar livremente, acelerando a obtenção desses recursos simultaneamente.

```
...
let ds_inits = tokio::join!(
    EnemDataSource::init(),
    EscolasDataSource::init());
...
```

Referências

- Araújo, R. A. (2019). Análise dos microdados do enade: proposta de uma ferramenta de exploração utilizando mineração de dados. Master's thesis, Universidade Federal De Goiás - Programa De Mestrado Em Ciência Da Computação.
- Filho, A. C. L. G., dos Santos, S. P., Trevisan, M., dos Santos, L. A., and Kocourek, S. (2025). Influência da renda no desempenho dos estudantes no enem: Uma análise longitudinal. *Gestão e Desenvolvimento*, 22(2).
- GitHub Team (2026). Github. <https://github.com/>.
- Inep (2025a). Dados abertos, microdados censo escolar 2024. <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar>.
- Inep (2025b). Dados abertos, microdados enem 2024. <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem>.
- Marcom, G. S. and Papani, M. P. (2024). The analysis of mathematics performance in the national high school exam in brazil. *Annales Universitatis Paedagogicae Cracoviensis — Studia Ad Didacticam Mathematicae Pertinentia*, 16(103-115).
- Rust Team (2026). Rust programming language. <https://www.rust-lang.org/>.
- Tertuliano, F. L. (2026). Repositório git. https://github.com/felipe-tertuliano/tcc_inep.

VSCode Team (2026). Visual studio code. <https://code.visualstudio.com/>.