

Mineração de Microdados do ENEM para Identificação de Escolas com Bom Desempenho em TIC em Contextos Socioeconômicos Desfavoráveis

Felipe Lacerda Tertuliano¹, Maria Inês Martins¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
30.535-901 - Belo Horizonte - MG - Brazil

Abstract. *This work proposes the development of an analytical mechanism to identify schools in the public basic education network as targets for training interventions in Information and Communication Technologies (ICT). Using microdata from ENEM and the School Census, the methodology involves large-scale data analysis that combines student performance in the national exam with socioeconomic indicators and school characteristics. The objective is to identify institutions with performance that deviates from expectations, thereby directing public policies and resources more effectively. This will result in a panel of indicators, which can contribute to applied data science, education, and training in ICT in Brazil.*

Resumo. *Este trabalho propõe o desenvolvimento de um mecanismo analítico para identificar escolas da rede pública de ensino básico como alvo para intervenções em capacitação em Tecnologias da Informação e Comunicação (TIC). Utilizando microdados do ENEM e do Censo Escolar, a metodologia envolve a análise de dados em larga escala, cruzando o desempenho dos estudantes no exame nacional com indicadores socioeconômicos e características das escolas. O objetivo é identificar instituições com desempenho que fogem ao esperado para direcionar políticas públicas e recursos de forma mais eficaz, resultando em um painel de indicadores, contribuindo para a ciência de dados aplicada à educação e à formação em TIC no Brasil.*

1. Introdução

A educação é o principal pilar para o desenvolvimento de qualquer área técnica, especialmente no processo de capacitação em que as condições materiais e sociais como a renda, ambiente de estudo, etnia ou gênero podem afetar as oportunidades e o desenvolvimento desses futuros profissionais. No Brasil a desigualdade social, a violência, baixos investimentos e vários outros fatores (característicos de países em desenvolvimento) afetam diretamente o processo de escolarização. Ainda assim, em condições desfavorável há casos escolares de sucesso, os quais são, entretanto, de difícil identificação e compreensão. Quais e como essas exceções geraram esses resultados? Esse trabalho tem como objetivo o desenvolvimento de um mecanismo analítico para identificar escolas-alvo para intervenções de capacitação em Tecnologias da Informação e Comunicação (TIC) para alunos da rede pública de ensino básico. O mecanismo de identificação se pautará em dados públicos, sobretudo no cruzamento de de informações extraídas dos microdados do Exame Nacional do Ensino Médio (ENEM) e dos microdados do Censo Escolar, ambos

disponibilizados anualmente pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Partindo do pressuposto de que o desempenho educacional em competências digitais depende, para além da infraestrutura tecnológica disponível, de fatores pedagógicos e institucionais, podemos identificá-los por meio da análise de dados educacionais em larga escala. Nesse contexto, a construção de um sistema de análise orientado por dados pode contribuir para orientar políticas públicas de formação e apoio às escolas, especialmente em contextos socioeconômicos mais vulneráveis. Os microdados contêm informações detalhadas sobre o desempenho dos participantes nas diferentes áreas do exame, variáveis relacionadas ao perfil socioeconômico dos estudantes e dados das escolas.

A proposta consiste em extrair, tratar e organizar esses dados utilizando técnicas de tratamento de grandes bases de dados, análise estatística e de agrupamento, possibilitando a construção de indicadores comparáveis entre escolas. A análise privilegia o cruzamento entre dois conjuntos de variáveis: 1. o desempenho dos estudantes em competências associadas ao uso e à compreensão de Tecnologias da Informação e Comunicação e 2. As características específicas da instituição de ensino em que esse participante se formou. Para o desempenho, foram consideradas competências presentes na Matriz de Referência (MR) do ENEM da área de Linguagens, Códigos e suas Tecnologias (C1 e C9) e na MR de Matemática e suas Tecnologias (C7), por estarem relacionadas a habilidades de interpretação de informações, resolução de problemas e uso de recursos tecnológicos e informacionais. Os indicadores das escolas permitem, de outro lado, caracterizar o perfil socioeconômico dos estudantes e construir índices sintéticos ou classificações que representem as instituições. O cruzamento entre desempenho nas competências selecionadas e a situação das escolas permite identificar padrões de desempenho que escapam às expectativas associadas às condições SE e, se possível, infraestruturais.

A identificação dessas unidades escolares, com desempenho resiliente, permite orientar ações de capacitação em TIC baseadas em evidências, direcionando recursos e estratégias para contextos em que tais intervenções possam produzir maior impacto. Como produto final, desenvolve-se um protótipo de mecanismo de identificação de escolas-alvo, que assume a forma de um painel analítico que permite visualizar e comparar indicadores educacionais e socioeconômicos. Espera-se que a proposta contribua tanto para o campo da ciência de dados aplicada à educação quanto para o aprimoramento de estratégias de formação em TIC no sistema educacional brasileiro.

2. Revisão de Literatura

O Exame Nacional do Ensino Médio (ENEM) foi criado em 1998 no Brasil com o intuito de avaliar a educação na rede de escolas do ensino médio nacionais. A adesão ao ENEM foi tímida nas primeiras edições do exame, mas ganhou força, a partir da edição de 2004, quando passou a ser o mecanismo de ingresso ao Programa Universidade para Todos (ProUni), com disputa nacional de bolsas de estudo em instituições privadas. O exame era feito em uma única tarde, composto por uma prova com 63 questões objetivas e uma redação. A sua consagração ocorre, a partir da sua edição de 2009, em que foi reestruturado para o modelo conhecido atualmente, e passou a ser também o mecanismo de ingresso ao Sistema de Seleção Unificada (Sisu). O exame passou a ser feito em 2 turnos, composto por uma redação e quatro provas de 45 questões cada uma, agrupadas

em área de conhecimento, a saber: Códigos, Linguagens e suas Tecnologias, Matemática e suas Tecnologias, Ciências da Natureza e suas Tecnologias e, Ciências Humanas e suas Tecnologias. O ENEM representa, na atualidade, a principal forma de democratização do ensino superior, configurando-se também como métrica para se avaliar o Ensino Médio, a etapa final da educação básica [BRASIL 2026] e prognosticar tendências na educação no país, como base concreta para o desenvolvimento de políticas públicas.

Entre outras ferramentas relevantes para o diagnóstico e o desenvolvimento da educação brasileira temos o Censo Escolar, coordenado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), o que permite o aprofundamento ainda maior na análise sobre o ensino Brasileiro. O Censo é preenchido anualmente e com caráter declarativo obrigatório para as escolas da educação básica. A plataforma provê dados da estrutura dessas instituições que também servem de métrica para ações no país. Tanto as informações do ENEM como do Censo Escolar são disponibilizadas em seu estado bruto, através de microdados, os quais se configuram como nossas principais fontes de dados.

Entretanto, somente a disponibilidade desses dados [Inep 2025b] [Inep 2025a] não permite um entendimento concreto sobre a educação, nem possibilita traçar uma abordagem compatível com a realidade do Brasil. Em "Influência da Renda no Desempenho dos Estudantes no Enem: uma Análise Longitudinal"[Garcez Filho et al. 2025], que fez uma análise de todas as edições do ENEM até 2023 cruzando os dados do questionário socioeconômico com as notas do exame, foi avaliado que, durante todos os anos, a renda familiar foi um fator decisivo para o desempenho dos alunos. Os autores também destacam a importância da ação direcionada para as escolas públicas e em situação desfavorável, pois são nessas escolas em que se encontram os estudantes mais afetados pela desigualdade social.

Especificamente quando se discute o desempenho nas áreas do conhecimento, disparidades mais complexas podem aparecer, como em "*The Analysis of Mathematics Performance in the National High School Exam in Brazil*"[Marcom and Papani 2024], em que se analisa o desempenho dos candidatos nos testes de matemática do ENEM 2022 com recortes geográficos e de gênero. Nele se mostrou que mulheres, em todos os casos, tinham piores resultados nessa área do exame, o que pode significar uma deficiência no nosso sistema educacional sobre o ensino de exatas.

Assim, a proposta do desenvolvimento de uma ferramenta capaz de mapear esses fatores e identificar pontos de atenção se mostra uma solução não apenas possível, mas também necessária. Na dissertação "Análise dos microdados do Enade: proposta de uma ferramenta de exploração utilizando mineração de dados"[Araújo 2019] utilizando metodologias de mineração e *machine learning* foi construída uma ferramenta *web* de análise. Entre os achados à partir dos dados foi possível gerar regras que representam condições de alunos no ensino superior, o que é uma forte ferramenta para intervenções direcionadas.

3. Metodologia

Baseado no objetivo do projeto foram escolhidas duas bases de dados a serem tratadas: microdados do ENEM 2024 [Inep 2025b] e microdados do censo escolar 2024 [Inep 2025a]. A partir dessas bases foi iniciada a produção de uma ferramenta na linguagem de programação *Rust* [Rust Team 2026] que seja capaz de ler os microdados, tratá-

los e processá-los, gerando enfim indicadores relevantes para a proposta. Um repositório [Tertuliano 2026] no *GitHub* [GitHub Team 2026] foi criado para o versionamento e foi escolhida a *IDE VSCode* [VSCode Team 2026] para o desenvolvimento. Entendendo que o projeto desenvolvido está sujeito a mudanças e possíveis extensões à depender de futuras pesquisas, optou-se pelo uso da arquitetura em N camadas [Buschmann et al. 1996] seguindo os princípios *SOLID* [Martin 2000] de desenvolvimento.

Para guiar a metodologia foi utilizado o processo *Knowledge Discovery in Databases* (KDD) [Fayyad et al. 1996], no qual se divide a mineração dos dados em etapas, cada uma com um objetivo a fim de melhorar a transformação de dados em informação, conhecimento e, enfim, em ação. Essa sessão será dividida em cinco subseções, cada uma representando e desenvolvendo uma parte do processo KDD, a saber: 1. Seleção, 2. Pre-processamento, 3. Transformação, 4. Mineração e 5. Interpretação.



Figura 1. Diagrama baseado no processo KDD [Fayyad et al. 1996]

3.1. Seleção

As bases dos resultados do ENEM quanto do Censo Escolar são obtidas a partir de um *link* na *internet* que permite o acesso livre à um arquivo *.zip* no qual se encontra um conjunto de elementos e, como foco para o projeto, um documento *.csv* contendo os dados. Seguindo o princípio de subsunção de Liskov (*SOLID*) foi projetado um elemento pai chamado *DataSource* que permite herança de suas funcionalidades para diferentes fontes e dois filhos representando cada uma das bases alvo.

Dentre as funcionalidades implementadas foi criado um fluxo de extração dos dados em três etapas, a saber: 1. Busca-se em um cliente *HTTP* o arquivo compactado das fontes, 2. Descompacta-se e salva-se o arquivo em um diretório local e 3. O documento *.csv* é acessado utilizando de um caminho pré-definido pelo usuário. Após o acesso a planilha, lê-se linha à linha e as colunas e seus respectivos valores são identificados e finalmente entram na parte de filtragem.

3.2. Pre-processamento

Seguindo a proposta de trabalho para os resultados do ENEM; é necessário avaliar quais dos participantes não faltaram ou foram eliminados das provas de Língua e Códigos e Matemática (áreas correlacionadas com a capacitação em TIC). Para isso foram removidos todos os elementos em que os campos "TP_PRESENCA.LC" e "TP_PRESENCA.MT" eram diferentes de "1", o que na base indica presença.

Ao analisar os dados do Censo Escolar [Inep 2025a] encontramos uma base com 426 campos, onde muitos desses podem causar ruídos durante o processo de classificação, então para diminuir a dimensionalidade do conjunto aplicamos a técnica de redução *PCA* [Jolliffe 2002]. Foram incluídos somente os elementos quantitativos descritos pelo prefixo "QT" (154 campos), esses passam pelas seguintes etapas: 1. Padronização dos valores, 2. Geração da Matriz de Covariância, 3. Geração dos Autovalores e 4. Seleção dos *K* campos com maiores autovalores.

3.3. Transformação

Para um melhor entendimento dos recortes SE das escolas foi escolhido o algoritmo *K-Means++* [Arthur and Vassilvitskii 2007], nele as escolas são agrupadas de forma não supervisionada e diferente do clássico *K-Means* as sementes são selecionadas de forma mais estratégica baseado em estatística. Assim é possível visualizar as características comuns e distintas das instituições e compará-las com seu desempenho no exame nacional.

3.4. Interpretação

Seguindo a proposta e metodologia deve ser desenvolvida uma interface gráfica de fácil utilização, capaz de ser executado de forma relativamente rápida em computadores de uso geral e exibir os dados obtidos pela mineração. Assim foi escolhida a biblioteca *Slint* [Slint Team 2026], uma ferramenta pouco intrusiva para códigos *Rust* que atende às demandas do projeto, com ela foram adicionados: comentários, um botão de execução do processo, uma barra de progresso para acompanhamento e uma tabela que exibe os resultados obtidos.




Figura 2. Interface do projeto desenvolvida em *Rust* [Rust Team 2026] com *Slint* [Slint Team 2026]

4. Implementações e Testes

Um dos requisitos propostos pelo trabalho é a criação de uma ferramenta capaz de ser utilizada e modificada para uso pessoal e em futuras pesquisas, portanto as prioridades ao desenvolver o projeto foram performance e manutenibilidade. A escolha da linguagem *Rust* [Rust Team 2026] se provou capaz de atender esses requisitos e com códigos assíncronos e paralelos utilizando da biblioteca *Tokio* [Tokio Team 2026] houve melhoria nos resultados. Em testes feitos com um computadores de uso geral (processador *Intel Core i3*, 16GB de memória RAM e GPU integrada) o fluxo completo de processamento das bases de dados do ENEM [Inep 2025b] e censo escolar [Inep 2025a] próximos de 4 milhões e 200 mil linhas respectivamente tiveram duração inferior à 5min.

5. Resultados Preliminares

Com o algoritmo PCA [Jolliffe 2002] conseguimos obter do censo escolar [Inep 2025a] os $K = 10$ campos quantitativos mais influentes da base de dados, a partir dos quais podemos traçar os indicadores socioeconômicos de modo mais fácil sem comprometer a acurácia, ao contrário do que ocorreria se utilizássemos todos os 154 campos.

Campo	Score
QT_SALAS_UTILIZADAS_DENTRO	28.2
QT_SALAS_UTILIZADAS_FORA	12.4
QT_SALAS_UTILIZADAS	10.7
QT_SALAS_UTILIZA_CLIMATIZADAS	7.3
QT_SALAS_UTILIZADAS_ACESSIVEIS	6.9
QT_EQUIP_DVD	5.1
QT_EQUIP_SOM	4.6
QT_EQUIP_TV	3.8
QT_EQUIP_LOUSA_DIGITAL	3.5
QT_EQUIP_MULTIMIDIA	3.3

Tabela 1. Resultado dos $K = 10$ campos quantitativos mais influentes do censo escolar [Inep 2025a] utilizando PCA [Jolliffe 2002]

Referências

- Araújo, R. A. (2019). Análise dos microdados do enade: proposta de uma ferramenta de exploração utilizando mineração de dados. Master's thesis, Dissertação (mestrado), Universidade Federal De Goiás - Programa De Mestrado Em Ciência Da Computação.
- Arthur, D. and Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *SODA '07: Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027 – 1035.
- BRASIL (2026). Decreto nº 12.915, de 30 de março de 2026. https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2026/decreto/d12915.htm. Acesso em: 29 de maio 2026.
- Buschmann, F., Meunier, R., Rohnert, H., Sommerlad, P., and Stal, M. (1996). *Pattern-Oriented Software Architecture, Volume 1: A System of Patterns*. Wiley.
- Fayyad, U., Piatetsky-Shapiro, G., and Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3).
- Garcez Filho, A. C. L., dos Santos, S. P., Trevisan, M., dos Santos, L. A., and Kocourek, S. (2025). Influência da renda no desempenho dos estudantes no enem: Uma análise longitudinal. *Gestão e Desenvolvimento*, 22(2).
- GitHub Team (2026). Github. <https://github.com/>.
- Inep (2025a). Dados abertos, microdados censo escolar 2024. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/censo-escolar>.
- Inep (2025b). Dados abertos, microdados enem 2024. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>.
- Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer.
- Marcom, G. S. and Papani, M. P. (2024). The analysis of mathematics performance in the national high school exam in brazil. *Annales Universitatis Paedagogicae Cracoviensis — Studia Ad Didacticam Mathematicae Pertinentia*, 16(103-115).

Martin, R. C. (2000). Design principles and design patterns. Object Mentor Inc. http://www.objectmentor.com/resources/articles/Principles_and_Patterns.pdf. Acesso em: 31 de maio 2026.

Rust Team (2026). Rust programming language. <https://www.rust-lang.org/>.

Slint Team (2026). Slint: A declarative gui toolkit for rust. Rust crate. Version 1.17.1.

Tertuliano, F. L. (2026). Repositório git. https://github.com/felipe-tertuliano/tcc_inep.

Tokio Team (2026). Tokio: A asynchronous runtime for rust. Rust crate. Version 1.52.1.

VSCoDe Team (2026). Visual studio code. <https://code.visualstudio.com/>.