

Mineração de Microdados do ENEM para Identificação de Escolas com Bom Desempenho em TIC em Contextos Socioeconômicos Desfavoráveis

Felipe Lacerda Tertuliano¹, Maria Inês Martins¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
30.535-901 - Belo Horizonte - MG - Brazil

Abstract. *This work proposes the development of an analytical mechanism to identify schools in the public basic education network as targets for training interventions in Information and Communication Technologies (ICT). Using microdata from ENEM and the School Census, the methodology involves large-scale data analysis, crossing student performance in the national exam with socioeconomic indicators and school characteristics. The objective is to identify institutions with performance that deviates from expectations to direct public policies and resources more effectively, resulting in a prototype, such as reproducible scripts or a panel of indicators, contributing to applied data science, education and training in ICT in Brazil.*

Resumo. *Este trabalho propõe o desenvolvimento de um mecanismo analítico para identificar escolas da rede pública de ensino básico como alvo para intervenções em capacitação em Tecnologias da Informação e Comunicação (TIC). Utilizando microdados do ENEM e do Censo Escolar, a metodologia envolve a análise de dados em larga escala, cruzando o desempenho dos estudantes no exame nacional com indicadores socioeconômicos e características das escolas. O objetivo é identificar instituições com desempenho que fogem ao esperado para direcionar políticas públicas e recursos de forma mais eficaz, resultando em um protótipo, como scripts reprodutíveis ou um painel de indicadores, contribuindo para a ciência de dados aplicada, à educação e a formação em TIC no Brasil.*

1. Introdução

A educação é o principal pilar para o desenvolvimento de qualquer área técnica, especialmente no processo de capacitação em que as condições materiais e sociais como a renda, ambiente de estudo, etnia ou gênero podem afetar as oportunidades e o desenvolvimento desses futuros profissionais. No Brasil a desigualdade social, violência, baixos investimentos e vários outros fatores (característicos de países de terceiro mundo) afetam diretamente o processo de escolarização ainda podemos verificar casos de sucesso, entretanto no meio de tantos exemplos é difícil identificar quais e como essas exceções geraram esses resultados. Esse trabalho tem como objetivo o desenvolvimento de um mecanismo analítico para identificar escolas-alvo para intervenções de capacitação em Tecnologias da Informação e Comunicação (TIC) para alunos da rede pública de ensino básico. O mecanismo de identificação se pautará em dados públicos, sobretudo no cruzamento de de informações extraídas dos microdados do Exame Nacional do Ensino Médio (ENEM)

e dos microdados do Censo Escolar, ambos disponibilizados anualmente pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Partindo do pressuposto de que o desempenho educacional em competências digitais depende, para além da infraestrutura tecnológica disponível, de fatores pedagógicos e institucionais, podemos identifica-los por meio da análise de dados educacionais em larga escala. Nesse contexto, a construção de um sistema de análise orientado por dados pode contribuir para orientar políticas públicas de formação e apoio às escolas, especialmente em contextos socioeconômicos mais vulneráveis. Os microdados contêm informações detalhadas sobre o desempenho dos participantes nas diferentes áreas do exame, variáveis relacionadas ao perfil socioeconômico dos estudantes e dados das escolas.

A proposta consiste em extrair, tratar e organizar esses dados utilizando técnicas de tratamento de grandes bases de dados, análise estatística e de agrupamento, possibilitando a construção de indicadores comparáveis entre escolas. A análise privilegiará o cruzamento entre três conjuntos de variáveis: 1. o desempenho dos estudantes em competências associadas ao uso e à compreensão de Tecnologias da Informação e Comunicação, 2. os indicadores socioeconômicos declarados pelos participantes no questionário contextual do ENEM e 3. As características específicas da instituição de ensino em que esse participante se formou. Para o desempenho, serão consideradas competências presentes na Matriz de Referência (MR) do ENEM da área de Linguagens, Códigos e suas Tecnologias (C1 e C9) e na MR de Matemática e suas Tecnologias (C7), por estarem relacionadas a habilidades de interpretação de informações, resolução de problemas e uso de recursos tecnológicos e informacionais. Os indicadores socioeconômicos permitirão, de outro lado, caracterizar o perfil dos estudantes e/ou da escola e construir índices sintéticos ou classificações que representem as instituições. O cruzamento entre desempenho nas competências selecionadas e a situação das escolas permitirá identificar padrões de desempenho que escapam às expectativas associadas às condições SE e, se possível, infraestruturais.

A identificação dessas unidades escolares, com desempenho resiliente, permitirá orientar ações de capacitação em TIC baseadas em evidências, direcionando recursos e estratégias para contextos em que tais intervenções possam produzir maior impacto. Como produto final, pretende-se desenvolver um protótipo de mecanismo de identificação de escolas-alvo, que poderá assumir a forma de um conjunto de rotinas de análise de dados, scripts reproduzíveis ou mesmo um painel analítico que permita visualizar e comparar indicadores educacionais e socioeconômicos. Espera-se que a proposta contribua tanto para o campo da ciência de dados aplicada à educação quanto para o aprimoramento de estratégias de formação em TIC no sistema educacional brasileiro.

2. Revisão Bibliográfica

Para um melhor entendimento do problema e análise de possíveis soluções foram analisados alguns trabalhos correlatos.

2.1. What does the National High School Exam (ENEM) tell Brazilian society?

What does the National High School Exam (ENEM) tell Brazilian society? [Travitzki et al. 2014] analisa o exame do ENEM e o censo escolar no contexto de 2009 e 2010 para avaliar o impacto e eficiência do exame no Brasil. A partir do trabalho foi

possível concluir que condições socioeconômicas explicavam a maior parte das diferenças de notas por escolas, e que pode ser injusta a avaliação dessas instituições por médias brutas, devido ao contexto. Um problema encontrado foi a amostragem, devido ao ENEM ser voluntário não é possível ter uma visão completa da situação da educação no país.

2.2. Socioeconomic Analysis of students who took the Enem between 2019 and 2022 using Machine Learning

Em *Socioeconomic Analysis of students who took the Enem between 2019 and 2022 using Machine Learning* [da Silva Macêdo et al. 2024] baseado nos testes do ENEM dos anos de 2019 até 2022 foi aplicado algoritmos de *machine learning* para traçar grupos e características que correlacionarem os resultados da prova com as condições socioeconômicas (SEs) dos participantes. Os resultados formaram dois grupos: alunos mal e bem sucedidos no exame, esses com correlação direta ao seu contexto SE, o que confirma a relevância desses indicadores para nosso objetivo. Entretanto foi observado que o numero reduzido de grupos pode ser um fator que limita conclusões mais profundas sobre possíveis intervenções, junto disso dado que a correlação entre o questionário SE e os resultados das provas foi removido para o ano de 2024, nossa metodologia deve considerar outras formas de extrair informações equivalentes.

2.3. Impact of Knowledge of Natural Sciences on ENEM Performance: Considerations about Scientific and Technological Inequality to Social Justice

No artigo *Impact of Knowledge of Natural Sciences on ENEM Performance: Considerations about Scientific and Technological Inequality to Social Justice* [Navarro et al. 2021] avalia o desempenho dos alunos na área das ciências naturais da prova do ENEM de 2017 e como esses resultados são afetados pela estrutura das escolas em que esses estudaram (rede de ensino e presença de laboratório de ciências). Os resultados mostram uma grande diferença na nota de alunos da rede publica e privada, onde mais da metade dos primeiros não alcançou 600 pontos, o que contrasta com o segundo grupo que teve um resultado oposto. A análise dos dados do ENEM por área de conhecimento junto do das escolas mostra uma importante forma de obter grupos e indicadores relevantes para o objetivo do trabalho.

2.4. Understanding a Profile of the Participants of the Exame Nacional do Ensino Médio (ENEM), Brazil, in the Year 2019, Through Data Analysis

Understanding a Profile of the Participants of the Exame Nacional do Ensino Médio (ENEM), Brazil, in the Year 2019, Through Data Analysis [de Souza et al. 2023] analisa dentro da base de dados dos participantes do ENEM 2019 fatores que podem influenciar os resultados na prova. Utilizando de algoritmos de análise de dados foi possível traçar relação direta entre condições socioeconômicas e as notas, igualmente para grupo étnico. Mesmo que para os dados do ENEM 2024 não seja possível mais fazer essa relação ainda o estudo é uma base para formas de tratar os dados e direcionar a perspectiva da análise.

2.5. Análise dos microdados do Enade: proposta de uma ferramenta de exploração utilizando mineração de dados

A dissertação *Análise dos microdados do Enade: proposta de uma ferramenta de exploração utilizando mineração de dados* [Araújo 2019] utiliza da base de dados do

Enade e metodologias de mineração e *machine learning* para construir uma ferramenta *web* de análise. Entre os achados da mineração foi possível gerar regras que representam condições de alunos dentro do ensino superior, o que pode ser uma forma de identificar públicos alvo. No geral a metodologia da dissertação pode ser utilizada como referência para atingir resultados com mais qualidade.

2.6. Clusters de Unidades Federativas do Brasil segundo características socioeconômicas e educacionais dos inscritos no Enem 2021

A dissertação *Clusters de Unidades Federativas do Brasil, segundo características socioeconômicas e educacionais dos inscritos no Enem 2021* [da Silva 2023] aplica técnicas de Análise de Agrupamentos (hierárquicas e k-means) aos microdados do Enem 2021 para investigar agrupamentos das Unidades Federativas (UFs) brasileiras. Com variáveis como instrução dos pais, ocupação da mãe e proporção de autodeclarados pretos, pardos ou indígenas, o estudo identifica clusters em algumas regiões geográficas, além de UFs isoladas (Ceará, Distrito Federal e Roraima). Os resultados mostram um cluster distinto formado por Rio de Janeiro e São Paulo, assim como pelos estados da região sul (Paraná, Santa Catarina e Rio Grande do Sul). Este trabalho é relevante para o presente estudo por demonstrar como a Análise de Agrupamentos pode ser aplicada aos dados do Enem para identificar padrões socioeconômicos e educacionais, servindo como referência metodológica para construir indicadores comparáveis entre escolas e identificar instituições com desempenho resiliente.

2.7. Fatores e evidências sobre o Exame Nacional do Ensino Médio (Enem): uma abordagem exploratória e experimental com mineração de dados

O estudo [Franco 2020] analisa os microdados do Enem de 1998 a 2019 por meio de algoritmos de seleção de atributos e classificadores, identificando que um conjunto reduzido de 10 fatores é capaz de classificar o desempenho estudantil com precisão média superior a 80%. Os resultados indicam que o tipo de escola cursada no Ensino Fundamental, a renda familiar, a escolaridade materna e a língua estrangeira escolhida estão entre os fatores mais preditivos. A pesquisa evidencia que a dimensionalidade dos dados pode ser reduzida sem perda significativa de acurácia, facilitando análises educacionais direcionadas.

2.8. Ensaios sobre o Desempenho dos Estudantes no ENEM 2017

A tese [Feijó 2019] analisa o desempenho de concluintes do ensino médio no ENEM 2017, abordando três fatores principais. O primeiro ensaio investiga a influência direta e indireta da escolaridade dos pais, mostrando que o controle por variáveis como renda e escola reduz significativamente o efeito bruto da educação parental, restando um efeito líquido entre 1% e 7%. O segundo ensaio utiliza decomposição quantílica para comparar escolas públicas e privadas, revelando que o diferencial de desempenho é explicado majoritariamente pelo efeito composição (background socioeconômico da turma e da família), enquanto o efeito estrutural é mais relevante nos quantis inferiores. O terceiro ensaio investiga a similaridade de gênero e raça entre professor e aluno, concluindo que alunas se beneficiam de professoras mulheres em Redação e Matemática, e alunos pretos/pardos se beneficiam de professores de Matemática da mesma raça, contribuindo para a redução do gap educacional.

2.9. Mineração em dados do ENEM para a predição do desempenho acadêmico no âmbito da Rede Federal de Educação Tecnológica

Nessa dissertação [de Santana Júnior 2018] se aplicou técnicas de mineração de dados sobre os microdados do ENEM 2014 para classificar o desempenho acadêmico de alunos provenientes da Rede Federal de Educação Tecnológica. Foram utilizados seis algoritmos de aprendizado de máquina (JRIP, PART, J48, Random Forest, Naive Bayes e SVM) em uma base pré-processada de 23.354 registros. Os experimentos demonstraram que os modelos Random Forest e Naive Bayes alcançaram as melhores métricas, com acurácia média de 74,32% e área sob a curva ROC de 0,817. O estudo também extraiu regras de classificação interpretáveis capazes de auxiliar gestores educacionais na identificação precoce de alunos com risco de baixo desempenho no exame.

2.10. Influência do acesso à internet e ao computador na proficiência de estudantes de baixa renda: uma análise com os participantes do ENEM entre 2015 e 2023

O estudo apresentado [de Oliveira Rubim 2024] investiga o impacto do acesso domiciliar à internet e ao computador no desempenho de estudantes de baixa renda no ENEM, utilizando uma amostra de 1,5 milhão de alunos entre 2015 e 2023. Por meio de modelos de regressão e técnicas de machine learning, a autora demonstra que o acesso combinado a ambos os recursos produz efeito significativo na proficiência, especialmente durante e após a pandemia de COVID-19, enquanto o acesso apenas à internet, predominantemente via dispositivos móveis, apresenta impacto positivo, porém modesto. O trabalho também evidencia desigualdades de gênero e regionais, reforçando a necessidade de políticas públicas alinhadas ao ODS 4.

3. Metodologia

Para o objetivo do projeto foram escolhidas duas base de dados a serem tratadas: microdados do ENEM 2024 [Inep 2025b] e microdados do censo escolar 2024 [Inep 2025a]. A partir dessas bases foi iniciada a produção de uma ferramenta na linguagem de programação *Rust* [Rust Team 2026] que seja capaz de ler os microdados, tratá-los e processá-los, gerando em fim indicadores relevantes para a proposta. Um repositório [Tertuliano 2026] no *GitHub* [GitHub Team 2026] foi criado para o versionamento e escolhida a *IDE VSCode* [VSCode Team 2026] para o desenvolvimento.

3.1. Extração dos dados

Para extrair os dados de ambas as bases [Inep 2025b] [Inep 2025a] foi criada uma característica chamada *Data Source* capaz de acessar a fonte na *internet*, baixar, descompactar e salvar essas localmente. Junto disso a *Data Source* seria capaz de percorrer o arquivo e obter os elementos a serem processados pelo programa.

```
...
pub trait DataSource<'a>: Sized {
    fn get_web_source(&self) -> String;

    fn get_source_path(&self) -> String;

    fn get_struct_path(&self) -> String;
```

```

fn new() -> Self;

fn get_ref(&self) -> GlobalRes<PathBuf> ...

fn get_header(&self) -> GlobalRes<Vec<String>> ...

async fn init() -> GlobalRes<Self> ...
}
...

```

Para a extração das múltiplas bases, devido a dependência de comunicação com a *internet* que gera grandes períodos de espera, essas foram colocadas para serem executadas de forma assíncrona. Dessa forma por enquanto ocorre hiatos em um processo o outro pode executar livremente, acelerando a obtenção desses recursos simultaneamente.

```

...
let ds_inits = tokio::join!(
    EnemDataSource::init(),
    EscolasDataSource::init());
...

```

Referências

- Araújo, R. A. (2019). Análise dos microdados do enade: proposta de uma ferramenta de exploração utilizando mineração de dados. Master's thesis, Universidade Federal De Goiás - Programa De Mestrado Em Ciência Da Computação.
- da Silva, E. B. (2023). Clusters de unidades federativas do brasil, segundo características socioeconômicas e educacionais dos inscritos no enem 2021. Master's thesis, Universidade Federal de Campina Grande - Programa de Pós-Graduação em Matemática (PROFMAT/CCT/UFCG).
- da Silva Macêdo, B., da Silva Macêdo, P., Barbosa, B. H. G., de Lima, C. M. V., Dias, P. M., Saporetti, C. M., and Goliatt, L. (2024). Socioeconomic analysis of students who took the enem between 2019 and 2022 using machine learning. *XLV Ibero-Latin American Congress on Computational Methods in Engineering*.
- de Oliveira Rubim, J. A. (2024). Influência do acesso à internet e ao computador na proficiência de estudantes de baixa renda: uma análise com os participantes do enem entre 2015 e 2023. Master's thesis, Universidade de São Paulo - Faculdade de Economia, Administração, Contabilidade e Atuária.
- de Santana Júnior, W. M. (2018). Mineração em dados do enem para a predição do desempenho acadêmico no âmbito da rede federal de educação tecnológica. Master's thesis, Universidade Federal de Pernambuco - Centro de Informática.
- de Souza, T. O., de Castro, A. F., and de Oliveira, A. G. (2023). Understanding a profile of the participants of the exame nacional do ensino médio (enem), brazil, in the year 2019, through data analysis. *Journal of Computer Science*, 19(7).

- Feijó, J. R. (2019). *Ensaio sobre o desempenho dos estudantes no Enem 2017*. PhD thesis, Universidade Federal do Ceará (UFC) - Programa de Pós-Graduação em Economia.
- Franco, J. J. (2020). Fatores e evidências sobre o exame nacional do ensino médio (enem): uma abordagem exploratória e experimental com mineração de dados. Master's thesis, Universidade Federal de Goiás - Instituto de Informática.
- GitHub Team (2026). Github. <https://github.com/>.
- Inep (2025a). Dados abertos, microdados censo escolar 2024. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/censo-escolar>.
- Inep (2025b). Dados abertos, microdados enem 2024. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>.
- Navarro, D., Ianello, M., Muneratto, F., and Watanabe, G. (2021). Impact of knowledge of natural sciences on enem performance: Considerations about scientific and technological inequality to social justice. *Revista Brasileira de Pesquisa em Educação em Ciências*.
- Rust Team (2026). Rust programming language. <https://www.rust-lang.org/>.
- Tertuliano, F. L. (2026). Repositório git. https://github.com/felipe-tertuliano/tcc_inep.
- Travitzki, R., Calero, J., and Boto, C. (2014). What does the national high school exam (enem) tell brazilian society? *CEPAL Review*, 2014(113).
- VSCoDe Team (2026). Visual studio code. <https://code.visualstudio.com/>.