

Mineração de Microdados do ENEM para Identificação de Escolas com Bom Desempenho em TIC em Contextos Socioeconômicos Desfavoráveis

Felipe Lacerda Tertuliano¹, Maria Inês Martins¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
30.535-901 - Belo Horizonte - MG - Brazil

Abstract. *This work proposes the development of an analytical mechanism to identify schools in the public basic education network as targets for training interventions in Information and Communication Technologies (ICT). Using microdata from ENEM and the School Census, the methodology involves large-scale data analysis that combines student performance in the national exam with socioeconomic indicators and school characteristics. The objective is to identify institutions with performance that deviates from expectations to direct public policies and resources more effectively, resulting in a prototype, such as reproducible scripts or a panel of indicators, contributing to applied data science, education, and training in ICT in Brazil.*

Resumo. *Este trabalho propõe o desenvolvimento de um mecanismo analítico para identificar escolas da rede pública de ensino básico como alvo para intervenções em capacitação em Tecnologias da Informação e Comunicação (TIC). Utilizando microdados do ENEM e do Censo Escolar, a metodologia envolve a análise de dados em larga escala, cruzando o desempenho dos estudantes no exame nacional com indicadores socioeconômicos e características das escolas. O objetivo é identificar instituições com desempenho que fogem ao esperado para direcionar políticas públicas e recursos de forma mais eficaz, resultando em um protótipo, como scripts reproduzíveis ou um painel de indicadores, contribuindo para a ciência de dados aplicada à educação e à formação em TIC no Brasil.*

1. Introdução

A educação é o principal pilar para o desenvolvimento de qualquer área técnica, especialmente no processo de capacitação em que as condições materiais e sociais como a renda, ambiente de estudo, etnia ou gênero podem afetar as oportunidades e o desenvolvimento desses futuros profissionais. No Brasil a desigualdade social, a violência, baixos investimentos e vários outros fatores (característicos de países em desenvolvimento) afetam diretamente o processo de escolarização. Ainda assim, em condições desfavorável há casos escolares de sucesso, os quais são, entretanto, de difícil identificação e compreensão. Quais e como essas exceções geraram esses resultados? Esse trabalho tem como objetivo o desenvolvimento de um mecanismo analítico para identificar escolas-alvo para intervenções de capacitação em Tecnologias da Informação e Comunicação (TIC) para alunos da rede pública de ensino básico. O mecanismo de identificação se pautará em dados públicos, sobretudo no cruzamento de de informações extraídas dos microdados do Exame Nacional do Ensino Médio (ENEM) e dos microdados do Censo Escolar, ambos

disponibilizados anualmente pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Partindo do pressuposto de que o desempenho educacional em competências digitais depende, para além da infraestrutura tecnológica disponível, de fatores pedagógicos e institucionais, podemos identifica-los por meio da análise de dados educacionais em larga escala. Nesse contexto, a construção de um sistema de análise orientado por dados pode contribuir para orientar políticas públicas de formação e apoio às escolas, especialmente em contextos socioeconômicos mais vulneráveis. Os microdados contêm informações detalhadas sobre o desempenho dos participantes nas diferentes áreas do exame, variáveis relacionadas ao perfil socioeconômico dos estudantes e dados das escolas.

A proposta consiste em extrair, tratar e organizar esses dados utilizando técnicas de tratamento de grandes bases de dados, análise estatística e de agrupamento, possibilitando a construção de indicadores comparáveis entre escolas. A análise privilegiará o cruzamento entre três conjuntos de variáveis: 1. o desempenho dos estudantes em competências associadas ao uso e à compreensão de Tecnologias da Informação e Comunicação, 2. os indicadores socioeconômicos declarados pelos participantes no questionário contextual do ENEM e 3. As características específicas da instituição de ensino em que esse participante se formou. Para o desempenho, serão consideradas competências presentes na Matriz de Referência (MR) do ENEM da área de Linguagens, Códigos e suas Tecnologias (C1 e C9) e na MR de Matemática e suas Tecnologias (C7), por estarem relacionadas a habilidades de interpretação de informações, resolução de problemas e uso de recursos tecnológicos e informacionais. Os indicadores socioeconômicos permitirão, de outro lado, caracterizar o perfil dos estudantes e/ou da escola e construir índices sintéticos ou classificações que representem as instituições. O cruzamento entre desempenho nas competências selecionadas e a situação das escolas permitirá identificar padrões de desempenho que escapam às expectativas associadas às condições SE e, se possível, infraestruturais.

A identificação dessas unidades escolares, com desempenho resiliente, permitirá orientar ações de capacitação em TIC baseadas em evidências, direcionando recursos e estratégias para contextos em que tais intervenções possam produzir maior impacto. Como produto final, pretende-se desenvolver um protótipo de mecanismo de identificação de escolas-alvo, que poderá assumir a forma de um conjunto de rotinas de análise de dados, scripts reproduzíveis ou mesmo um painel analítico que permita visualizar e comparar indicadores educacionais e socioeconômicos. Espera-se que a proposta contribua tanto para o campo da ciência de dados aplicada à educação quanto para o aprimoramento de estratégias de formação em TIC no sistema educacional brasileiro.

2. Revisão de Literatura

O Exame Nacional do Ensino Médio (ENEM) foi criado em 1998 no Brasil com o intuito de avaliar a educação na rede de escolas do ensino médio nacionais. A adesão ao ENEM foi tímida nas primeiras edições do exame, mas ganhou força, a partir da edição de 2004, quando passou a ser o mecanismo de ingresso ao Programa Universidade para Todos (ProUni), com disputa nacional de bolsas de estudo em instituições privadas. O exame era feito em uma única tarde, composto por uma prova com 63 questões objetivas e uma redação. A sua consagração ocorre, a partir da sua edição de 2009, em que foi

reestruturado para o modelo conhecido atualmente, e passou a ser também o mecanismo de ingresso ao Sistema de Seleção Unificada (Sisu). O exame passou a ser feito em 2 turnos, composto por uma redação e quatro provas de 45 questões cada uma, agrupadas por área de conhecimento, a saber: Códigos, Linguagens e suas Tecnologias, Matemática e suas Tecnologias, Ciências da Natureza e suas Tecnologias e, Ciências Humanas e suas Tecnologias. O ENEM representa, na atualidade, a principal forma de democratização do ensino superior, configurando-se também como métrica para se avaliar o Ensino Médio, a etapa final da educação básica [?] e prognosticar tendências na educação no país, como base concreta para o desenvolvimento de políticas públicas.

Entre outras ferramentas relevantes para o diagnóstico e o desenvolvimento da educação brasileira temos o Censo Escolar, coordenado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), o que permite o aprofundamento ainda maior na análise sobre ensino Brasileiro. Sendo feito anualmente e com caráter declarativo obrigatório para as escolas da educação básica o censo provê dados da estrutura dessas instituições que também servem de métrica para ações no país. Tanto as informações do ENEM como do Censo Escolar são disponibilizadas em seu estado bruto, através de microdados, os quais se configuram como nossas principais fonte de dados.

Entretanto, somente a disponibilidade desses dados [?] [?] não permite um entendimento concreto sobre a educação, nem muito traçar uma abordagem compatível com a realidade do Brasil. Em "Influência Da Renda No Desempenho Dos Estudantes No Enem: Uma Análise Longitudinal"[?], que fez uma análise de todas as edições do ENEM até 2023 cruzando os dados do questionário socioeconômico com as notas do exame, foi avaliado que durante todos os anos a renda familiar foi um fator decisivo para a nota dos alunos. Nele também é constatada a importância da ação direcionada para as escolas públicas e em situação desfavorável, pois são nessas escolas em que se encontram os estudantes mais afetados pela desigualdade social.

Especificamente quando se discute o desempenho nas áreas do conhecimento, disparidades mais complexas podem aparecer, como em "*The Analysis of Mathematics Performance in the National High School Exam in Brazil*"[?], em que se analisa o desempenho dos candidatos nos testes de matemática do ENEM 2022 com recortes geográficos e de gênero. Nele se mostrou que mulheres, em todos os casos, tinham piores resultados nessa área do exame, o que pode significar uma deficiência no nosso sistema educacional sobre o ensino de exatas.

Assim, a proposta do desenvolvimento de uma ferramenta capaz de mapear esses fatores e identificar pontos de atenção se mostra uma solução não apenas possível, mas também necessária. Na dissertação "Análise dos microdados do Enade: proposta de uma ferramenta de exploração utilizando mineração de dados"[?] utilizando metodologias de mineração e *machine learning* foi construída uma ferramenta *web* de análise. Entre os achados à partir dos dados foi possível gerar regras que representam condições de alunos no ensino superior, o que é uma forte ferramenta para intervenções direcionadas.

3. Metodologia

Para o objetivo do projeto foram escolhidas duas bases de dados a serem tratadas: microdados do ENEM 2024 [?] e microdados do censo escolar 2024 [?]. A partir dessas bases foi iniciada a produção de uma ferramenta na linguagem de programação *Rust* [?]

que seja capaz de ler os microdados, tratá-los e processá-los, gerando enfim indicadores relevantes para a proposta. Um repositório [?] no *GitHub* [?] foi criado para o versionamento e escolhida a *IDE VSCode* [?] para o desenvolvimento. Entendendo que o projeto desenvolvido está sujeito a mudanças e possíveis extensões à depender de futuras pesquisas, foi optado pelo uso da arquitetura em N camadas [?] seguindo os princípios *SOLID* [?] de desenvolvimento.

Para guiar a metodologia foi utilizado o processo *Knowledge Discovery in Databases* (KDD) [?], no qual se é dividido a mineração dos dados em etapas, cada uma com um objetivo a fim de melhorar a transformação de dados em informação, conhecimento e enfim em ação. Essa sessão será dividida em cinco subseções, cada uma representando e desenvolvendo uma parte do processo KDD, que são: 1. Seleção, 2. Pre-processamento, 3. Transformação, 4. Mineração e 5. Interpretação.

3.1. Extração dos dados

Tanto as bases dos resultados do ENEM quanto do Censo Escolar são obtidas a partir de um *link* na *internet* que permite o acesso livre à um arquivo *.zip* onde dentro desse se encontra um conjunto de elementos e, como foco para o projeto, um documento *.csv* contendo os dados. Seguindo o princípio de subsunção de Liskov (*SOLID*) foi projetado um elemento pai chamado *DataSource* que permite herança de suas funcionalidades para diferentes fontes e dois filhos representando cada uma das bases alvo.

Dentre as funcionalidades implementadas foi criado um fluxo de extração dos dados em três etapas, onde: 1. É buscado via um cliente *HTTP* o arquivo compactado das fontes, 2. Esse é descompactado e salvo em um diretório local e 3. O documento *.csv* é acessado utilizando de um caminho pré-definido pelo usuário. Após o acesso a planilha, é lida linha à linha e as colunas e seus respectivos valores são identificados e finalmente entram na parte de filtragem.

3.2. Filtragem dos dados

Seguindo a proposta de trabalho para os resultados do EMEM é necessário avaliar quais dos participantes não faltaram ou foram eliminados das provas de Língua e Códigos e Matemática (áreas correlacionadas com a capacitação em TIC). Para isso foram removidos todos os elementos em que os campos "TP_PRESENCA_LC" e "TP_PRESENCA_MT" eram diferentes de "1", o que na base indica presença.

4. Resultados Esperados

A partir desse trabalho se espera ter construída uma plataforma capaz de fornecer visualmente informações relevantes sobre a rede de ensino básico em situações socioeconômicas desfavoráveis, seja no país ou recorte geográfico (município por exemplo), em relação a qualidade da formação de competências em TIC. Essa ferramenta deve ser de fácil manipulação e modificação, ou seja, garantir uma baixa curva de aprendizado para projeções de diversas áreas e permitir complementos ou alterações para usos em futuros projetos. Outro resultado, e não menos importante, é o desenvolvimento de uma metodologia para a identificação das escolas alvo partindo dos princípios já descritos, assim garantindo uma base sólida para intervenções e pesquisas.